

Detección Automática de Malezas en Imágenes de Plantas

Recuperación de Información y Recomendaciones en la Web
Grupo 02 – Curso 2025

Facultad de Ingeniería, UDELAR

Detección Automática de Malezas en Imágenes de Plantas

1. Problema

1.1 Motivación

1.2 Introducción

1.3 Objetivos

1.4 Desafíos

2. Solución

2.1 Arquitectura y herramientas

2.2 Dónde entra la RI?

2.3 Redes Neuronales



2.4 Datasets

2.5 Modelos clasificadores

2.5.1 YOLO, Faster R-CNN y SSD

2.6 Resultados y evaluación

3. Conclusiones



Detección Automática de Malezas en Imágenes de Plantas



1. Problema

- 1.1 Motivación
- 1.2 Introducción
- 1.3 Objetivos
- 1.4 Desafíos

2. Solución

- 2.1 Arquitectura y herramientas
- 2.2 Dónde entra la RI?
- 2.3 Redes Neuronales
- 2.4 Datasets
- 2.5 Modelos clasificadores
 - 2.5.1 YOLO, Faster R-CNN y SSD
- 2.6 Resultados y evaluación

3. Conclusiones



1.1 Motivación

- **Las malezas representan una de las principales amenazas para los cultivos**, compitiendo con los cultivos por agua, luz y nutrientes, lo que reduce significativamente el rendimiento agrícola.
- **Detectarlas de forma temprana y precisa es clave**, pero hacerlo manualmente implica altos costos de tiempo, personal y recursos.
- **La inteligencia artificial, en particular la visión por computadora**, ofrece una oportunidad para automatizar este proceso de manera eficiente, rápida y escalable.
- **Aplicaciones accesibles desde un navegador** permiten acercar estas tecnologías a usuarios reales, incluso en entornos con recursos limitados.




1.2 Introducción

- El avance de la inteligencia artificial y la visión por computadora ha permitido automatizar tareas complejas como la detección de objetos en imágenes.
- En este proyecto se desarrolla una aplicación web que permite identificar la presencia de malezas en imágenes de plantas cargadas por el usuario.
- El sistema combina técnicas de recuperación de información visual con modelos de redes neuronales profundas, logrando analizar y clasificar imágenes de forma automática y en tiempo real.



1.3 Objetivos

- Crear un prototipo funcional y accesible desde el navegador.
- Implementar detección automática basada en visión por computadora.
- Evaluar el rendimiento del sistema con métricas estándar.



1.4 Desafíos

- **Falta de modelos específicos para malezas:** la mayoría de los modelos preentrenados están pensados para objetos genéricos.
- **Variabilidad en las imágenes:** las condiciones de luz, el fondo, la calidad de la cámara y la diversidad de especies afectan la calidad y precisión del modelo.
- **Balance entre precisión y rendimiento:** se buscó mantener un sistema liviano que funcione en entorno web, sin sacrificar demasiado la calidad de detección.
- **Evaluación confiable de resultados:** fue necesario definir un conjunto de pruebas para poder medir objetivamente el rendimiento del sistema con métricas estándar.

El alcance de los desafíos está acotado por los tiempos ofrecidos por la materia para realizar el proyecto.

Detección Automática de Malezas en Imágenes de Plantas

1. Problema

1.1 Motivación

1.2 Introducción

1.3 Objetivos

1.4 Desafíos

2. Solución

2.1 Arquitectura y herramientas

2.2 Dónde entra la RI?

2.3 Redes Neuronales



2.4 Datasets

2.5 Modelos clasificadores

2.5.1 YOLO, Faster R-CNN y SSD

2.6 Resultados y evaluación

3. Conclusiones



2.1 Arquitectura y herramientas

Principales herramientas utilizadas:

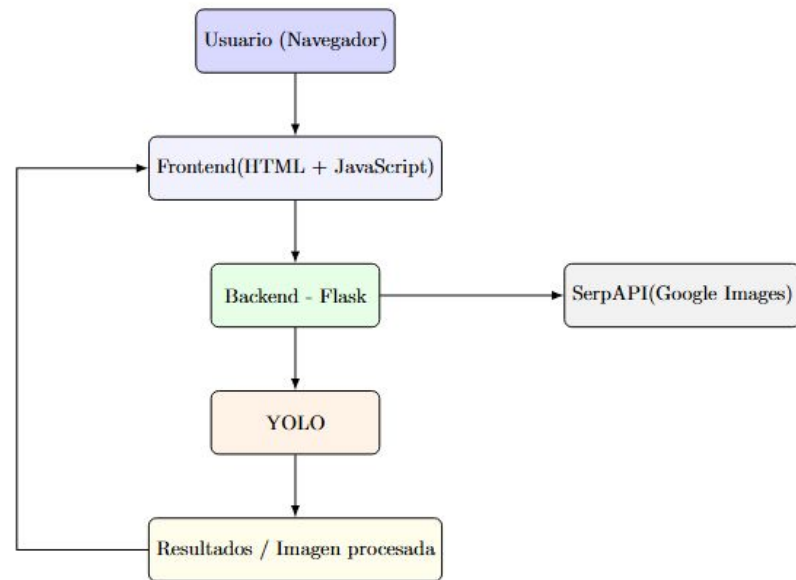
- **Flask (Python):** microframework para crear la API REST que recibe las imágenes, ejecuta la detección y devuelve el resultado.
- **YOLOv8 (Ultralytics):** modelo de detección de objetos entrenado desde cero a partir de un dataset seleccionado de plantas con y sin malezas.
- **HTML + JavaScript:** base del frontend web. Permite al usuario cargar imágenes y visualizar los resultados en una interfaz simple.
- **SerpAPI:** se integra para realizar búsquedas de imágenes en Google a partir de texto libre ingresado por el usuario.



2.1 Arquitectura y herramientas

Arquitectura:

- **Frontend (HTML + JS):** recibe input del usuario y muestra los resultados.
- **API's (Flask + SerpAPI):** conecta la interfaz con el modelo, gestiona predicciones y búsquedas.
- **Modelo YOLO v8:** entrenado con un dataset real, detecta malezas en imágenes cargadas o buscadas.
 - El modelo hace una interpretación semántica (extracción de conocimiento) desde la imagen, análogo a un motor de búsqueda.



2.2 Dónde entra la RI?


- La RI no se limita a texto: también aplica a imágenes, audio y video.
- En este proyecto, la imagen es la consulta.
- El sistema “recupera” dos elementos clave:
 - Por un lado imágenes (buscadas a partir de una API).
 - Por otro lado la información relevante sobre la imagen seleccionada: maleza o no.
- La red neuronal actúa como mecanismo de interpretación semántica de esa consulta visual.

2.3 Redes Neuronales





Clasificador

Modelo que etiqueta una entrada según sus características



Función de activación

Operación que permite a las redes aprender relaciones complejas




Redes Convolucionales

Diseñadas para procesar imágenes



Atención

Enfoque de partes de las imágenes



2.4 Datasets



2.4 Datasets



2.4 Datasets



0 0.478516 0.560547 0.847656 0.625000
<class_id> <x_center> <y_center> <width> <height>

2.4 Datasets



+4500 imágenes



0 0.478516 0.560547 0.847656 0.625000
<class_id> <x_center> <y_center> <width> <height>

Entrenamiento

Validación

Pruebas



76%

13%

11%


2.5 Modelos Clasificadores

CONVOLUTIONAL NEURAL NETWORK (CNN)




2.5 Modelos Clasificadores

CONVOLUTIONAL NEURAL NETWORK (CNN)




Cómo hacer un modelo?




2.5 Modelos Clasificadores

CONVOLUTIONAL NEURAL NETWORK (CNN)



Cómo hacer un modelo?





2.5.1 YOLO, Faster R-CNN y SSD

Faster R-CNN

Single shot
multibox detector
(SSD)

You Only Look
Once (YOLO)



2.5.1 YOLO, Faster R-CNN y SSD

Faster R-CNN

Single shot
multibox detector
(SSD)





You Only Look
Once (YOLO)

El más rápido, ideal para
respuesta en tiempo real

Una sola etapa

Muy buena precisión



2.6 Resultados y evaluación

YOLOv3

YOLOv8L

YOLOv5

YOLOv8n

YOLOv6

YOLOv8s

YOLOv4

YOLOv9



YOLOv11

YOLOv8x

2.6 Resultados y evaluación


YOLOv8L


Se priorizó la precisión en la detección por encima del rendimiento computacional y la velocidad.



2.6 Resultados y evaluación

Progresiva disminución de las pérdidas y aumento sostenido de precisión, recall y mAP





Detección Automática de Malezas en Imágenes de Plantas

1. Problema

1.1 Motivación

1.2 Introducción

1.3 Objetivos

1.4 Desafíos

2. Solución

2.1 Arquitectura y herramientas

2.2 Dónde entra la RI?

2.3 Redes Neuronales



2.4 Datasets

2.5 Modelos clasificadores

2.5.1 YOLO, Faster R-CNN y SSD

2.6 Resultados y evaluación


3. Conclusiones



Maleza

3. Conclusiones

- YOLOv8L logró altos niveles de precisión (94.2), y recall (91.4)
- El modelo es adecuado para tareas de clasificación en campo
- Futuras mejoras pueden incluir aumento de datos, nuevos escenarios
- El modelo detecta correctamente múltiples objetos con alta confianza



¿ PREGUNTAS ?

MUCHAS GRACIAS

Integrantes:

Matías Forcelledo,
Guzman Pieroni,
Juan Cabrera